

# **DataOps Foundation**

## **From DevOps to Data Production**

กระบวนการนำเข้าข้อมูลสีบเชื่อสู่คลังข้อมูล

**mindData-Technology**

บริษัท มายด์ดาต้า เทคโนโลยี จำกัด

December 15, 2025

1 Overview

2 Extract


3 Transform

4 Load

5 Validation

6 Summary

# ການຮວມຂອງ ETL Pipeline



CSV File

Python/Pandas

MSSQL

- **Extract:** อ่านข้อมูลจาก CSV (LoanStats\_web.csv)
- **Transform:** ทำการสังเคราะห์ แปลง และสร้าง Star Schema
- **Load:** นำเข้าสู่ MSSQL Data Warehouse

# ขั้นตอนที่ 1: Extract - อ่านข้อมูล

## กำหนด Data Type อัตโนมัติ

```
def guess_column_types(file_path):
    df = pd.read_csv(file_path)
    for column in df.columns:
        # Check datetime: YYYY-MM-DD HH:MM:SS
        # Check date: YYYY-MM-DD
        # Use pandas infer_dtype()
    return column_types
```

พึงกշับนี้จะ:

- ตรวจสอบรูปแบบวันที่และเวลาอัตโนมัติ
- กำหนด Data Type ที่เหมาะสมให้แต่ละคอลัมน์

# ขั้นตอนที่ 2: Transform - จัดการ Missing Values

## กลยุทธ์การจัดการค่าว่าง (2 ระดับ)

### ระดับที่ 1: กรองคอลัมน์

- ลบคอลัมน์ที่มี  $\text{NULL} > 30\%$

```
missing_percentage = df.isnull().mean() * 100
```

### ระดับที่ 2: กรองแคว

- เลือกคอลัมน์ที่มี  $\text{NULL} \leq 26$  และ
- ลบแควที่เหลือที่ยังมีค่าว่าง

```
noNull_df = df_selected.dropna()
```

# ขั้นตอนที่ 2: Transform - แปลงข้อมูล

## การแปลงข้อมูลให้พร้อมใช้งาน


### 1. แปลงวันที่

```
df['issue_d'] = pd.to_datetime(  
    df['issue_d'], format='%b-%Y')  
# "Jan-2020" -> 2020-01-01
```

### 2. แปลงอัตราดอกเบี้ย

```
df['int_rate'] = df['int_rate']  
    .str.rstrip('%').astype('float') / 100.0  
# "15.5%" -> 0.155
```

## ขั้นตอนที่ 2: Transform - Star Schema Design



# ขั้นตอนที่ 2: Transform - สร้าง Dimension Tables

## ขั้นตอนการสร้าง Dimension Table

### Step 1: ดึงค่าที่ไม่ซ้ำกัน

```
home_ownership_dim = df[['home_ownership']]  
    .drop_duplicates().reset_index(drop=True)
```

### Step 2: สร้าง Primary Key

```
home_ownership_dim['home_ownership_id'] = \  
    home_ownership_dim.index
```

ผลลัพธ์:

home_ownership_id	home_ownership
0	RENT
1	OWN
2	MORTGAGE

# ขั้นตอนที่ 2: Transform - สร้าง Fact Table

## การ Map Foreign Key

### Step 1: สร้าง Dictionary สำหรับ Mapping

```
home_ownership_map = home_ownership_dim \
    .set_index('home_ownership')['home_ownership_id'] \
    .to_dict()
# {'RENT': 0, 'OWN': 1, 'MORTGAGE': 2}
```

### Step 2: แทนที่ค่าด้วย Foreign Key

```
loans_fact['home_ownership_id'] = \
    loans_fact['home_ownership'].map(home_ownership_map)
```

# ขั้นตอนที่ 3: Load - นำเข้าสู่ MSSQL

## เชื่อมต่อและนำเข้าข้อมูล

```
from sqlalchemy import create_engine

engine = create_engine(
    f'mssql+pymssql://{{user}}:{{pwd}}@{{server}}/{{db}}')

# Load Dimension Tables
home_ownership_dim.to_sql('home_ownership_dim',
    con=engine, if_exists='replace', index=False)
loan_status_dim.to_sql('loan_status_dim',
    con=engine, if_exists='replace', index=False)
issue_d_dim.to_sql('issue_d_dim',
    con=engine, if_exists='replace', index=False)

# Load Fact Table
loans_fact.to_sql('loans_fact',
    con=engine, if_exists='replace', index=False)
```


# การตรวจสอบความถูกต้อง

## ทดสอบ Join ทุก Table

```
final_df = pd.merge(loans_fact,  
                    home_ownership_dim, on='home_ownership_id')  
final_df = pd.merge(final_df,  
                    loan_status_dim, on='loan_status_id')  
final_df = pd.merge(final_df,  
                    issue_d_dim, on='issue_d_id')
```

### ตรวจสอบ:

- จำนวนแคลวต้องเท่ากับข้อมูลต้นฉบับ
- ค่า Measure ต้องตรงกัน
- ไม่มีค่า NULL หลัง Join



# ขอบคุณครับ

Q&A